



JORNADAS DATA SCIENCE CON IA

***OPORTUNIDADES
DEL DATA SCIENCE
EN 2026***

APUNTES DÍA 1

ACCEDE AL REPLAY DE LA SESIÓN 1 AQUÍ

INTRODUCCIÓN

¡Qué gran sesión vivimos ayer!

Dar el primer paso siempre es lo que más cuesta, pero ayer demostraste que vas en serio con tu carrera profesional, y viste todo el potencial que tiene esta carrera si conviertes a la IA en tu copiloto.

Como vimos muchísima información en directo y no quiero que te satures intentando recordarlo todo, he preparado este apunte para ti.

Aquí tienes recopilado y organizado todo lo que viste en nuestra primera jornada para que lo asimiles a tu ritmo.

Tómalo como tu guía personal para repasar todo lo que descubriste ayer:

☞ Entender el famoso **"Triángulo del Data Science"** y comprobar cómo la Inteligencia Artificial ha cambiado las reglas del juego asumiendo la parte técnica más pesada.

☞ Descubrir **qué hace exactamente cada perfil del mundo de los datos** gracias a nuestra "metáfora del restaurante", para que sepas rápidamente dónde encajas tú.

☞ Conocer la **tabla de salarios reales del mercado** y por qué esta profesión tiene una demanda imparable.

☞ Repasar el paso a paso de la **demo** en Google Colab, donde vimos cómo **limpiar datos y aplicar un modelo predictivo** para encontrar a los mejores clientes de un negocio sin picar código.

Léelo con calma y asienta estos conceptos, porque en la segunda sesión vamos a ensuciarnos las manos metiéndonos en la piel de un Data Scientist para resolver 3 casos reales.

Nos vemos en el próximo directo,

Gerard Sánchez

LAS OPORTUNIDADES DEL DATA SCIENCE EN 2026


Vivimos en la era de los datos. Cada acción que realizamos deja una huella digital. Cada clic, cada búsqueda y cada interacción genera información que se almacena, analiza y convierte en conocimiento.

El volumen es enorme: más de **300.000 millones de correos electrónicos al día**, **500 millones de tweets** y **720.000 horas de contenido en YouTube**.

Más del 90% de los datos existentes se han creado en los últimos dos años. El volumen es abrumador: se estima que **cada día se generan más de 300.000**.

LOS DATOS SE HAN CONVERTIDO EN EL RECURSO MÁS VALIOSO DEL SIGLO XXI.

El desafío ya no es almacenarlos, sino entenderlos y convertirlos en decisiones útiles. **Eso es exactamente lo que hace el Data Science o Ciencia de Datos.**



1) QUÉ ES EL DATA SCIENCE

El Data Science es la disciplina que convierte datos en conocimiento, predicción y ventaja competitiva. Parte de una idea sencilla pero potente: tanto las personas como los procesos siguen patrones.


Si tienes suficientes datos históricos, puedes detectar esos patrones y anticipar lo que va a pasar.

El proceso tiene **tres fases**:

1. **Entender el pasado:** Analizar datos históricos para saber qué ocurrió y por qué.
2. **Descubrir patrones ocultos:** Usando estadística y modelos para encontrar relaciones no evidentes. *Ejemplo:* identificar qué combinaciones de factores anticipan un comportamiento.
3. **Predecir y decidir:** Proyectar el futuro y tomar decisiones más precisas. *Ejemplo:* prever qué clientes abandonarán un servicio o qué producto tendrá mayor demanda.

En resumen: *datos → conocimiento → predicción → acción*


El valor no está en el modelo, sino en **las decisiones que ese modelo permite tomar**.



2) EL TRIÁNGULO DEL DATA SCIENCE

El Data Scientist no se apoya en una sola disciplina, sino en la intersección de tres:

1. Matemáticas y Estadística.
2. Informática y Programación
3. Negocio y Comunicación.



1- Matemáticas y Estadística

Estas disciplinas son el punto de partida. Pero ¿Por qué?

Permiten entender los datos, encontrar relaciones y validar si los resultados tienen sentido.

En la práctica, **el Data Scientist no inventa los algoritmos: los aplica correctamente.**

Veamos algunos ejemplos concretos:

- Regresión para estimar cómo afecta el precio o la publicidad a las ventas.
- Clustering (K-Means) para agrupar clientes por comportamiento.
- Árboles de decisión para predecir si un cliente va a cancelar un servicio.
- Series temporales para prever la demanda futura.

Evaluemos algunos un ejemplo real:

Un banco quiere estimar el **riesgo de impago**. El Data Scientist usa una **regresión logística**, la entrena con el historial del banco y obtiene una **probabilidad por cliente**. El valor está en preparar bien los datos y asegurarse de que **el modelo es fiable**.

En resumen, las matemáticas y la estadística son lo que nos permiten **dar sentido a los datos**.

Pero para aplicar todo esto a millones de registros y automatizar los cálculos, necesitamos la siguiente pieza del triángulo: **la informática y la programación**.

Veamos de que se trata.

2- Informática y Programación

Ya vimos que las matemáticas y la estadística nos dicen qué hacer con los datos. Ahora es el turno de **la informática, la parte práctica: cómo obtener, limpiar, organizar y procesar datos a gran escala**.

En la realidad, **los datos nunca vienen listos**: están dispersos, tienen errores y formatos inconsistentes.

De hecho, una **gran parte del trabajo** (hasta el 80% del tiempo) consiste en **preparar los datos** antes de analizarlos.

Repasemos entonces cuales suelen ser los pasos para ello:

1. **Recolectar datos** de bases de datos, APIs, archivos o redes sociales.
2. **Limpiar y transformar la información** para que sea coherente y usable.
3. Aplicar modelos de machine learning con librerías como Scikit-learn, TensorFlow o PyTorch.
4. **Visualizar resultados con Matplotlib**, Seaborn o Power BI.
5. **Automatizar procesos** para que los análisis se ejecuten de forma periódica.

Todo esto se hace normalmente con **lenguajes como Python, SQL o R** (que son el puente entre el análisis y la tecnología).

Veamos como se aplicaría en el día a día de un Data Scientist:

Imagina un supermercado que recopila millones de tickets de compra cada mes.

El Data Scientist usa **SQL** para **extraer** los datos de las bases de datos, **Python** para **limpiarlos y unirlos**, y luego aplica modelos estadísticos para detectar **patrones de consumo**.

Al final, se genera un **dashboard visual** que muestra qué productos se compran juntos o qué días hay más ventas.

Pongámoslo de esta manera:

Sin informática ni programación, todo ese análisis sería imposible.

Estas herramientas permiten hacer realidad los modelos matemáticos a gran escala, repetir los experimentos con precisión y convertir lo teórico en resultados medibles. En otras palabras: **la programación pone en marcha el motor del Data Science.**

Y para que ese motor tenga dirección y sentido, necesitamos el **tercer pilar del triángulo: el Conocimiento de Negocio y la Comunicación**, que transforman los resultados en **decisiones**.

3- Negocio y Comunicación

Este es el pilar más importante. Pero ¿por qué?

Esto se debe a que es justo aquí es donde **la ciencia de datos se convierte en valor real**.

Verás. Muchos Data Scientists cometen el **error** de perderse en lo técnico, olvidando que el objetivo no es crear el modelo más complejo, sino **resolver un problema de negocio**.

El valor de este pilar está es que permite:

1. **Entender el contexto:** por qué analizamos estos datos y qué decisión hay que tomar.
2. **Formular las preguntas correctas** antes de empezar cualquier modelo.
3. **Traducir resultados técnicos** en **conclusiones** que otros puedan usar.
4. **Comunicar hallazgos** con un lenguaje que entiendan los responsables de la decisión (no técnico).

Pero ¿cómo se vería esto con un ejemplo práctico?

Imagina esta situación: Un modelo detecta con 95% de precisión qué clientes van a abandonar un servicio.

Si el Data Scientist no traduce eso en "*contactar a los clientes con más de tres incidencias abiertas*", el modelo no sirve de nada. **El valor no está en la predicción, sino en la acción que genera.**

Por esto mismo, un Data Scientist debe tener también **mentalidad de negocio**: saber qué problema resolver, medir el impacto y comunicarlo con claridad.

Cómo ya mencionamos, el objetivo final no es escribir código, sino mejorar **resultados**.

En resumen, este tercer pilar es el que completa el "círculo" del Data Scientist que todas las empresas buscan:

Aplicar fórmulas > Analiza los Datos > Interpreta resultados > Traduce eso e conclusiones y pasos lógicos a seguir > Los comunica de forma clara y coherente para tomar acciones de negocio estratégicas.

Sin negocio no hay dirección, sin comunicación no hay impacto. Los datos solo cuentan una historia si alguien sabe interpretarla y transmitirla.

Hay que dominar las diferentes disciplinas que comprenden al Data Science.

Pero ¿por qué decimos que ahora es más fácil?

Veamos donde es que entra la Inteligencia Artificial (IA), y cómo es que puede realizar el trabajo pesado y técnico por ti.

Cómo la IA Generativa actualiza el triángulo

Durante años, **dominar el Data Science requería años de formación técnica.**

Pero hoy, **la IA generativa actúa como un asistente técnico o un copiloto dentro del proceso:** puede ayudarte a escribir código, limpiar datos, documentar pasos o generar visualizaciones.

Lo que **antes era una barrera técnica alta**, ahora es una colaboración: tú aportas el criterio y el conocimiento del negocio; la IA se encarga de la ejecución técnica más repetitiva.

¿Es un buen trato, verdad? ¡Pero ojo! Esto no significa que debemos entregarle control completo a la IA.

DE TÉCNICO A SOLUCIONADOR DE PROBLEMAS

Lo importante ya no es escribir cada línea de código desde cero.

Es entender los **flujos de trabajo del Data Science**, saber **interpretar el código que genera la IA y ajustarlo a tu problema concreto.**

El Data Scientist no es un programador. **Es un solucionador de problemas** que usa herramientas de programación para entender, predecir y decidir.

Hoy, la **inteligencia artificial está transformando ese triángulo** y abriendo la puerta a una nueva generación de profesionales de datos.


Y, con ayuda de la IA, es cada vez más rápido, y fácil adaptar tu perfil y experiencia cómo estrategia de negocio, vengas del ámbito que vengas, para convertirte en uno de los **perfiles más buscados del mercado**.

¿CÓMO USAR LA IA GENERATIVA PARA TOMAR VENTAJA EN EL MUNDO DE LOS DATOS?

Cómo ya mencionamos, La IA generativa (como ChatGPT, Gemini o Claude) actúa como un asistente técnico y analítico dentro del proceso de Data Science.

Puede ayudarte a **escribir código, limpiar datos, documentar pasos o generar visualizaciones**, tareas que antes requerían mucho tiempo o conocimiento técnico.

El problema de la hoja en blanco ha desaparecido: ahora el verdadero valor está en **saber qué pedir, cómo adaptarlo y cómo interpretar los resultados**.



El nuevo triángulo del Data Scientist

3) DISCIPLINAS DENTRO DEL DATA SCIENCE

El Data Science no es una sola cosa. En realidad, abarca un ecosistema de disciplinas que comparten el mismo objetivo: **extraer conocimiento útil de los datos para tomar mejores decisiones.**

Veamos cuales son y de que se tratan, para entender mejor el panorama completo actual de la analítica y la inteligencia artificial (y cómo se complementan todas las partes entre sí):

a) Big Data: la Materia Prima

Cómo dijimos: **todo comienza con los datos.**

Las empresas y los dispositivos conectados generan cada segundo una **cantidad inmensa de información**: transacciones, clics, ubicaciones, sensores, texto, imágenes o vídeos.

Big Data no es una técnica, sino un entorno de trabajo. Se refiere al fenómeno de **datos tan voluminosos, variados y veloces** (las 3 V) que requieren tecnologías específicas para almacenarlos y procesarlos (*Hadoop, Spark*, bases de datos en la nube).

En resumen: **Big Data es la infraestructura que hace posible el Data Science.**

b) Inteligencia Artificial (IA)

Este es el campo más amplio, y su objetivo es **crear sistemas capaces de realizar tareas que normalmente requieren inteligencia humana**: razonar, planificar, aprender, comunicarse.

Bajo este paraguas conviven múltiples enfoques: desde sistemas basados en reglas (con condiciones predefinidas), hasta modelos que aprenden solos de los datos. Y son estos últimos los que conforman una subdisciplina esencial dentro de la IA moderna: el **Machine Learning**.

c) Machine Learning: Aprender del Pasado

El Machine Learning permite **que las máquinas aprendan a partir de ejemplos**, sin programar cada paso.

El modelo **descubre patrones** en datos históricos y los usa para hacer predicciones sobre nuevos casos.

Existen dos grandes tipos:


- **Aprendizaje supervisado:** Se entrena con datos que ya incluyen la respuesta correcta (etiquetas). Ejemplo: enseñar a un modelo miles de correos clasificados como “spam” o “no spam” para que aprenda a reconocer nuevos. Se utiliza para clasificación, regresión o predicción (ventas, riesgo, fraude, churn...).
- **Aprendizaje no supervisado:** Los datos no tienen etiqueta; el modelo busca por sí mismo estructuras, patrones o grupos. Ejemplo: segmentar clientes en función de su comportamiento de compra sin saber previamente cuántos grupos hay. Se utiliza para agrupamiento, detección de anomalías o reducción de dimensionalidad.

Ejemplo de aprendizaje supervisado: clasificación de imágenes de gatos y perros

Para que lo entiendas mejor, veamos un ejemplo práctico simple: La clasificación de imágenes de gatos y perros.

Este es un caso clásico de aprendizaje supervisado. Queremos entrenar un modelo capaz de distinguir si una imagen contiene un gato 🐱 o un perro 🐶.

El modelo aprende a partir de ejemplos etiquetados, donde ya sabemos cuál es la respuesta correcta.



1. Datos de entrenamiento

Reunimos miles de imágenes, cada una con su etiqueta:

- gato 🐱
- perro 🐶

Esas etiquetas son la clave del aprendizaje supervisado: le indican al modelo cuál es la respuesta correcta en cada ejemplo.

2. Entrenamiento del modelo

El modelo (por ejemplo, una red neuronal convolucional) analiza cada imagen y aprende a reconocer patrones visuales:


- Los bordes y formas de las orejas.
- La textura del pelaje.
- La forma del hocico o los ojos.
- A lo largo del proceso, el modelo ajusta sus parámetros internos para reducir los errores entre sus predicciones y las etiquetas reales.

3. Evaluación y validación

Una vez entrenado, probamos el modelo con imágenes nuevas que nunca ha visto. Si generaliza bien, clasificará correctamente la mayoría como "gato" o "perro".

4. Predicción

Cuando recibe una nueva imagen sin etiqueta, el modelo devuelve una probabilidad: 0,92 gato / 0,08 perro. Se interpreta que el modelo está un 92% seguro de que la imagen contiene un gato.



En resumen: el modelo **aprende** a partir de ejemplos del pasado (**imágenes etiquetadas**) para **tomar decisiones** sobre nuevos casos.

Este mismo principio se aplica a clasificar correos, detectar fraudes o predecir si un cliente va a cancelar un servicio.

d) Deep Learning: Aprender de la Experiencia

El **Deep Learning** (aprendizaje profundo) es una **ramificación del Machine Learning** basada en **redes neuronales artificiales** con muchas capas de procesamiento.

Cada capa extrae progresivamente características más complejas de los datos, lo que permite resolver problemas que antes eran inalcanzables.

Gracias al Deep Learning hoy son posible cosas cómo:

- Reconocimiento facial y de voz.
- Traducción automática de idiomas.
- Sistemas de conducción autónoma.
- Diagnósticos médicos a partir de imágenes.

Estos modelos requieren **gran potencia computacional y volúmenes masivos de datos**, pero han impulsado una auténtica revolución en cómo las máquinas perciben y entienden el mundo.

e) LLMs: el siguiente paso del aprendizaje automático



Mientras que el **Machine Learning tradicional** se centra en predecir un valor numérico o una categoría (por ejemplo, estimar la demanda del próximo mes o si un cliente comprará o no), los LLMs aprenden a **predecir la siguiente palabra, píxel o fragmento de código** según el contexto, utilizando modelos de Deep Learning.

En su forma más conocida, los **LLMs (Large Language Models)**, se entrenan con enormes volúmenes de texto (gran parte del contenido público de internet) para **predecir la palabra más probable que sigue en una secuencia**.

Esa tarea, aparentemente sencilla, les permite aprender la estructura estadística del lenguaje: cómo se relacionan las palabras, cómo se organizan las ideas y cómo mantener la coherencia en una conversación o texto.

Por eso pueden generar respuestas completas, escribir código, resumir información o explicar conceptos de forma natural.

Pero ¿Cómo funcionan los LLMs?

Lejos de funcionar por arte de magia, estos modelos siguen los mismos principios que cualquier modelo de machine learning: **datos, entrenamiento, optimización y validación**.

La diferencia está en la **escala** y en la **arquitectura** (los Transformers), capaces de manejar dependencias complejas entre elementos de una secuencia.

Por eso, estos modelos **no están fuera del alcance del Data Scientist**: es una **evolución** dentro del mismo marco técnico y conceptual, basada en los mismos fundamentos matemáticos y estadísticos.

De hecho, los grandes modelos que usamos (como ChatGPT, Gemini o Claude) han sido creados y entrenados por Data Scientists e ingenieros de machine learning.

Y somos nosotros quienes preparamos los datos, ajustamos los modelos y evaluamos su rendimiento, adaptándolos a contextos reales.

Entrenamientos de modelos generativos

Aunque entrenar un modelo desde cero requiere grandes infraestructuras, en la práctica la mayoría de proyectos actuales se basan en ajustar (fine-tuning) modelos existentes o enriquecerlos con conocimiento adicional mediante técnicas como RAG (Retrieval-Augmented Generation), que permiten conectarlos a bases de datos o documentos internos.

Así, un Data Scientist puede **entrenar o personalizar un modelo generativo** con los datos y lenguaje de su empresa, o **conectarlo a fuentes actualizadas** para que responda con información contextual y relevante.

En definitiva, **no solo usamos estos modelos**, sino que **los diseñamos, adaptamos y ponemos en producción** como parte de soluciones de negocio completas.

Los LLMs (un subconjunto especializado especializado de IA generativa enfocado específicamente en **comprender y generar texto humano**), también se han convertido en una **herramienta de apoyo diario, un copiloto** dentro del flujo de trabajo del Data Science.

Nos ayuda a **escribir y depurar código, documentar pipelines, explicar resultados técnicos en lenguaje natural y automatizar informes o visualizaciones**.

Incluso puede **sugerir hipótesis** o acelerar la exploración de datos, liberándonos de tareas repetitivas y permitiéndonos centrarnos en **el razonamiento, la interpretación y el impacto del análisis**.

4) EL DATA SCIENCE ESTÁ EN TODAS PARTES

El Data Science no pertenece a un solo sector.

Hoy en día, está presente en **prácticamente todas las industrias**, porque donde hay datos, hay oportunidades para entender mejor los procesos, anticipar comportamientos y tomar decisiones más inteligentes.

Aquí tienes algunos ejemplos por sector:

Banca y finanzas: del riesgo a la personalización

La banca es uno de los sectores más maduros y con experiencia en el uso del Data Science. Y es que aquí los datos son críticos porque cada decisión implica riesgo y dinero.

Los modelos se aplican para:

- **Evaluar el riesgo de impago:** para predecir la probabilidad de que un cliente no devuelva un préstamo, ayudando a **prevenir pérdidas**.
- **Detectar fraudes en tiempo real:** identifican patrones anómalos en transacciones que podrían **indicar actividad sospechosa**.
- **Predecir la propensión a contratar productos:** estiman quiénes tienen **más probabilidad** de abrir una cuenta, solicitar una hipoteca o cambiar de banco.

El **Data Scientist financiero** es quien diseña, entrena y monitoriza estos modelos para que sean rentables, ya que en banca, los datos son el nuevo activo: **quien los entiende, gestiona el riesgo y anticipa oportunidades**.

Salud: datos que salvan vidas

En el sector sanitario, el Data Science se traduce en **diagnósticos más rápidos, tratamientos personalizados y detección temprana de enfermedades**.

Trabajar con datos en salud exige entender biología, cuerpo humano y procesos clínicos. Es uno de los campos más complejos y con **mayor impacto social**.

El **Data Scientist en salud** trabaja en colaboración con médicos, bioingenieros y farmacéuticos, convirtiendo datos clínicos en información accionable.

Algunos ejemplos clave de esta industria podrían ser:

- Análisis de imágenes médicas con modelos de Deep Learning para identificar tumores o anomalías en radiografías y resonancias.
- Predicción de reingresos hospitalarios o complicaciones clínicas usando historiales médicos.
- Descubrimiento de fármacos acelerado mediante modelos que analizan millones de combinaciones químicas.

Retail: entender al cliente para vender mejor

Esta industria depende cada vez más del análisis de datos para **comprender el comportamiento del consumidor y marcar diferencia frente a competidores**.

Las aplicaciones más comunes incluyen:

- **Sistemas de recomendación:** sugerir productos según compras previas (como Amazon o Zara).
- **Análisis de cesta:** qué productos se compran juntos para diseñar promociones efectivas.
- **Predicción de demanda:** gestionar inventario y evitar roturas de stock.

El Data Scientist del sector retail es un mix de: analítica, marketing y operaciones para **optimizar la experiencia del cliente y aumentar los márgenes**.

Marketing: de la intuición al dato

El marketing ha pasado de tomar decisiones por intuición a basarse en datos.

Ya no se diseñan funnels de ventas y campañas “porque sí”.

Al tener un Data Scientist en sus equipos, las empresas logran:

- **Segmentar clientes** según comportamiento, intereses o valor potencial.

- **Medir el impacto real de cada canal**, identificando qué estrategias generan más conversiones o fidelidad.
- **Identificar los mejores clientes** que convertiran o comprarán tus productos.

El **Data Scientist de marketing** convierte los datos en información clara: quién es, qué necesita y cómo comunicarse con él.

Esta combinación de analítica y creatividad permite campañas más efectivas.

Otros sectores en transformación

- **Transporte y logística**: optimización de rutas, predicción de demanda y gestión de flotas inteligentes.
- **Energía**: predicción de consumo, mantenimiento predictivo en redes eléctricas y optimización de energías renovables..
- **Gobierno y administraciones públicas**: análisis de datos sociales, detección de fraude y mejora de servicios ciudadanos.

En todos estos ámbitos, el Data Scientist aporta el mismo valor: **transformar datos en conocimiento y conocimiento en acción**.

El Data Science es hoy el lenguaje común de la innovación. Allí donde hay decisiones que pueden basarse en evidencia, **hay un Data Scientist detrás**.

5. ¿POR QUÉ ESTÁ CRECIENDO TANTO ESTA PROFESIÓN?

El **Data Science** se ha convertido en el **motor de la transformación digital global**.

Veamos algunos datos que explican este presente de forma más clara:

88%

El 88% de las organizaciones ya usa IA regularmente.

Pero casi dos tercios siguen en fase piloto sin haber escalado

Fuente: McKinsey State of AI, noviembre 2025

\$581.
700M

La inversión global en IA se duplicó en 2025

De ~\$300B a más de \$580B en un solo año

Fuente: Stanford HAI AI Index 2026

88%

El 23% de las empresas ya escala agentes de IA

No solo pilotos: sistemas autónomos que toman decisiones

Fuente: McKinsey 2025

Según el World Economic Forum ([Future of Jobs Report 2025](#)), entre 2025 y 2030 se crearán **más de 170 millones de nuevos empleos.**

Los Data Scientists, Big Data Specialists y AI & Machine Learning Specialists están entre los perfiles de **mayor crecimiento.**

El problema no es la falta de tecnología. Es la **falta de personas capaces** de hacer que esa tecnología funcione con datos reales, en contextos reales, y conectada a decisiones de negocio.

En resumen:

Las empresas necesitan **profesionales que unan el análisis con el negocio**, que construyan **modelos predictivos o generativos**, y que lideren la **integración de la IA** en cada decisión estratégica.

El **Data Scientist** es el puente entre los datos y la acción, y por eso está en el centro de la revolución económica y tecnológica de la próxima década.

Pero si aún quedan dudas o no sabes bien que de todo esto te calza mejor, vamos a repasar algunos de los **perfiles que podemos encontrar en el mundo de los datos.**

5) PERFILES DENTRO DEL MUNDO DE LOS DATOS

En el ecosistema del Data Science no existe un único “trabajo de datos”, sino varios perfiles que colaboran entre sí.

Cada rol tiene una **función específica** dentro del proceso: desde recopilar y organizar los datos hasta crear modelos predictivos o desplegarlos en sistemas reales.

Data Analyst: convierte los datos en conocimiento

El **Data Analyst** se centra en **analizar, interpretar y visualizar datos** para responder preguntas concretas del negocio. Su trabajo es descubrir qué está pasando y por qué.

Qué hace:

- Extrae y limpia datos de distintas fuentes (bases de datos, hojas de cálculo, CRM, etc.).
- Crea informes, dashboards y visualizaciones que facilitan la toma de decisiones.
- Identifica patrones, tendencias y anomalías.

Herramientas habituales:

Excel, SQL, Power BI, Tableau, Python (Pandas, Matplotlib, Seaborn).

El Data Analyst traduce datos en información comprensible para todos los niveles de la organización.

Data Scientist: predice y explica el futuro

El **Data Scientist** va un paso más allá: usa técnicas estadísticas, machine learning y deep learning para **construir modelos predictivos o explicativos**.

Analiza grandes volúmenes de datos para detectar patrones y anticipar comportamientos.

Qué hace:

- Formula hipótesis y experimentos basados en datos.
- Entrena modelos de predicción o clasificación.
- Evalúa resultados y comunica conclusiones de forma clara.

Herramientas habituales:

Python, Pandas, NumPy, Scikit-Learn, PyTorch, Jupyter Notebooks.

El Data Scientist no solo analiza, sino que **enseña a las máquinas a aprender del pasado para predecir el futuro**.

Data Engineer: construye la base del sistema

El **Data Engineer** diseña y mantiene la **infraestructura que permite que los datos fluyan correctamente**.

Sin su trabajo, los analistas y científicos no tendrían datos fiables ni accesibles.

Qué hace:

- Crea y gestiona pipelines de datos (extracción, transformación y carga).
- Asegura la calidad, escalabilidad y seguridad de los datos.
- Trabaja con grandes volúmenes y arquitecturas distribuidas.

Herramientas habituales:

SQL, Apache Spark, Airflow, Kafka, AWS, Google Cloud, Databricks.

El Data Engineer es el **arquitecto de los datos**, responsable de que toda la información llegue limpia, completa y a tiempo.

Machine Learning/AI Engineer: lleva los modelos a producción

El **Machine Learning Engineer** o **AI Engineer** es quien convierte los modelos creados por los Data Scientists en **productos reales y escalables**.

Se sitúa entre el mundo de la ciencia de datos y el desarrollo de software.

Qué hace:

- Implementa y optimiza modelos para que funcionen en entornos reales.
- Automatiza despliegues y monitoriza el rendimiento.
- Garantiza que los modelos sean reproducibles, eficientes y seguros.

Herramientas habituales:

TensorFlow, PyTorch, Docker, APIs REST, Git, MLflow, MLOps, CI/CD.

El ML Engineer **lleva la inteligencia artificial a la práctica**, integrando modelos en aplicaciones y servicios usados por millones de personas.

Metáfora: el restaurante del Data Science

Para que recuerdes cómo encajan los perfiles, vamos a verlo con una metáfora:

Imagina que el Data Science es un restaurante.

Todos trabajan con los mismos ingredientes (los datos), pero cada perfil cumple una función distinta en su manipulación:

- **Data Engineer → El proveedor.** Se encarga de que los ingredientes (datos) lleguen limpios, ordenados y listos para usar. Sin él, la cocina no puede empezar.
- **Data Scientist → El chef.** Usa los ingredientes para crear recetas (modelos) que aporten valor. Prueba, ajusta y mejora hasta encontrar la combinación perfecta. Convierte los datos en conocimiento.
- **Data Analyst → El camarero.** Presenta el plato al cliente (el negocio). Explica de forma clara qué significa el análisis y qué decisiones se pueden tomar. Hace que los datos sean comprensibles.
- **ML / AI Engineer → El jefe de cocina automatizado.** Toma la receta ganadora y la automatiza para producirla a gran escala con calidad constante. Lleva los modelos del laboratorio a la realidad.

Competencias clave en todos los perfiles

Más allá de las herramientas, el éxito en el mundo de los datos depende de **habilidades transversales** que marcan la diferencia:

- **Pensamiento analítico:** saber descomponer un problema y formularlo en términos de datos.
- **Conocimiento de negocio:** entender el contexto y el impacto de cada análisis.
- **Comunicación:** explicar resultados complejos de forma sencilla.
- **Trabajo en equipo:** colaborar entre perfiles técnicos y no técnicos.
- **Curiosidad y aprendizaje continuo:** mantenerse al día en un campo que evoluciona constantemente.

Las herramientas cambian. Las competencias se mantienen.

Cualquier perfil puede reconvertirse

No hace falta venir de la ingeniería o las matemáticas para entrar en este mundo.

De hecho, los profesionales de **marketing, finanzas o recursos humanos** tienen una ventaja: **conocen el negocio, la industria, y tienen una visión estratégica del negocio.**

Aprender a analizar datos solo amplía su capacidad para tomar decisiones y aportar valor desde su experiencia.

El Data Science no es solo para programadores: es para **personas que quieren entender, mejorar y decidir mejor usando datos.**

6) CONDICIONES LABORALES Y OPORTUNIDADES REALES EN ESPAÑA (2026)

El Data Science no solo crece en importancia, sino también en **demanda y remuneración**.

Las empresas españolas compiten por atraer talento en análisis, ingeniería y modelado de datos.

Los salarios varían según **experiencia, sector y ciudad**, pero todos los perfiles disfrutan de **alta estabilidad, teletrabajo y posibilidades de crecimiento**.

PERFIL	EXPERIENCIA	RANGO SALARIAL
DATA ANALYST	Junior	25k - 35k € / año
	Mid	33k - 47k € /año
	Senior	39k - 53k € / año
DATA SCIENTIST	Junior	28k - 40k € / año
	Mid	38k - 50k €/ año
	Senior	40k - 60k €/ año
DATA ENGINEER	Junior	25k - 45k €/ año
	Mid	40k - 55k € / año
	Senior	46k - 60k € / año

Fuente: Glassdoor Barcelona (España)

Estos datos confirman que el **Data Science** se ha consolidado como uno de los sectores mejor valorados y con mayor proyección profesional en España.

Esto se debe también a varios factores. Vamos a ver algunos de ellos:

Oportunidades de empleo y condiciones

- Trabajo remoto o híbrido, con flexibilidad horaria y enfoque en objetivos.
- Cultura tecnológica y experimental: probar y equivocarse forma parte del proceso.
- Colaboración constante entre perfiles de negocio, tecnología y datos.
- Alta movilidad: las habilidades de datos son globales y transferibles.
- Upskilling continuo: las empresas valoran el aprendizaje constante y la adaptación.

Convertirse en un profesional de datos en España hoy implica acceder a un mercado con **buenas condiciones remunerativas y alta demanda**, pero el que marca la diferencia no sólo domina la técnica: **entiende el negocio, comunica resultados y genera impacto**.

La técnica abre la puerta. Pero lo que marca la diferencia es la **capacidad de transformar datos en decisiones reales con impacto medible**.

Y lo mejor: esta tendencia no es temporal.

A medida que la **inteligencia artificial** y la **automatización** se integran en todos los sectores, la demanda de profesionales de datos seguirá creciendo en España y en el mundo.

Las habilidades de un Data Scientist son globales y transferibles: **el idioma de los datos no tiene fronteras**.

7) DATA SCIENCE E IA GENERATIVA: EL NUEVO FLUJO DE TRABAJO

La **IA generativa** no sustituye al Data Scientist: **lo complementa y amplifica**.

Sigue siendo el profesional quien diseña los análisis, valida los resultados y toma decisiones.

La IA actúa como un **asistente técnico** que acelera tareas repetitivas, facilita la programación y reduce las barreras de entrada al campo.

En otras palabras, **hace el Data Science más asequible y accesible** a perfiles que antes lo veían demasiado técnico.

Cómo la IA generativa potencia el flujo de trabajo

- **Asistencia en código y documentación:** Herramientas como ChatGPT, Cursor, Copilot, Colab AI o WindSurf ayudan a escribir y depurar código, documentar funciones y entender errores. No reemplazan el conocimiento: permiten concentrarse en la lógica y el análisis en lugar de la sintaxis.
- **Exploración y preparación de datos:** Modelos como Gemini o Claude pueden generar resúmenes iniciales, detectar valores atípicos o sugerir transformaciones. El Data Scientist sigue siendo quien **elige las variables relevantes y valida la calidad del análisis**.
- **Prototipado de modelos:** La IA puede crear un borrador de modelo con Scikit-Learn, PyTorch o XGBoost, pero el ajuste y la interpretación final **requieren criterio y experiencia humana**.
- **Comunicación de resultados:** ChatGPT o Copilot pueden redactar informes y explicar métricas, pero **la traducción al contexto del negocio y la validación de conclusiones** siguen siendo responsabilidad del profesional.

Ejemplo práctico

Un Data Scientist puede pedir a [ChatGPT](#) o [Gemini](#):

“Explora este dataset y sugiere qué variables predicen la fuga de clientes.”

La IA genera un análisis preliminar y algunas hipótesis. Después, **el profesional revisa, ajusta y valida los resultados**.

El proceso es más rápido y accesible, lo que **reduce la brecha técnica para quienes se inician en el campo** sin perder rigor en el trabajo final.

El nuevo equilibrio

Cómo dijimos antes, la IA generativa libera tiempo de tareas mecánicas y democratiza el acceso al análisis avanzado.

Permite que más personas participen en proyectos de datos y que los Data Scientists se enfoquen en lo que realmente importa:

- Formular buenas **preguntas**.
- Elegir la **metodología** adecuada.
- Interpretar con **criterio**.
- Conectar los resultados con **decisiones** de negocio.

La IA ayuda a escribir el código, pero no entiende el contexto. El valor sigue en quien **piensa, valida y convierte los datos en conocimiento útil**.

CONCLUSIÓN

Las empresas tienen más datos que nunca, más inversión en IA que nunca y siguen habiendo pocos profesionales capaces de conectar todo eso con decisiones de negocio reales.

El Data Scientist del futuro no es el que más herramientas domina, sino **el que sabe preguntar, interpretar y comunicar**.

La IA generativa democratiza el acceso a las herramientas; **el valor humano está en el criterio, el contexto y la responsabilidad**.

Si debes quedarte con algo, es con esto:

Los datos están en todas partes. Las personas que saben usarlos, no.

REPASEMOS LA DEMO EN DIRECTO: ANALÍTICA DE NEGOCIO CON GOOGLE COLAB

Al final del primer día realizamos una demo en directo usando Google Colab.


El objetivo era que puedas ver en acción **el flujo de trabajo real de un Data Scientist**: desde dos tablas de datos en bruto hasta conclusiones de negocio accionables, pasando por limpieza, cruce de tablas, visualizaciones interactivas y un modelo de clustering no supervisado.

Te recomendamos tener a mano la [grabación de la clase de ayer](#) para poder seguir el proceso paso a paso en imagen.

Pero primero, vamos a aclarar algunos conceptos clave:

¿Qué es Google Colab?

Piénsalo como tu cuaderno de trabajo en la nube de Google. Con Google Colab te olvidas de instalar nada en tu ordenador, configurar entornos o preocuparte por si tu equipo tiene suficiente potencia, porque esta plataforma vive directamente en tu navegador y se apoya en la infraestructura de Google. Entrás con tu cuenta de Google y ya tienes un entorno listo para ejecutar código Python, con librerías de Data Science preinstaladas (como Pandas, NumPy, Matplotlib, Seaborn, Scikit-learn y más), además de acceso gratuito a GPUs y TPUs para cuando tus proyectos necesiten más músculo computacional. Es el entorno flexible y colaborativo que te permite compartir tu trabajo con cualquier persona con un simple enlace, igual que harías con un documento de Google Docs.



Nuestra materia prima: Los datos de la demo

Para este caso, trabajamos con dos archivos (en formato .csv) que simulan los datos reales de una empresa. Piénsalo como dos piezas de un rompecabezas que necesitamos unir:

 `clientes_master_demo.csv` **(La radiografía del cliente):**

Aquí tenemos una fila por cada usuario con toda su "personalidad" de compra. Incluye variables como: edad, antigüedad, segmento (Starter / Growth / Premium / Enterprise), región, canal de adquisición preferido, industria, CLV estimado (lo que creemos que gastará en toda su vida), número de pedidos en los últimos 12 meses, NPS (si nos recomendaría), sensibilidad al descuento, ticket medio, fecha de última compra, propensión al churn (riesgo de que nos abandone) y su score de valor.

 `interacciones_marketing_demo.csv` **(Su comportamiento):**

Aquí registramos cada vez que ese cliente interactúa con nosotros. Recoge el canal (Instagram, LinkedIn, Email, etc.), formato, objetivo de campaña, impresiones, clics, engagements, likes, comentarios, shares, guardados, conversiones, gasto, ingresos, lead score y sentimiento.

La magia de cruzarlos: Tener estos datos por separado no sirve de mucho. Lo que hicimos fue unir ambas tablas buscando su punto en común: el campo `client_id` (que funciona como el DNI de cada usuario). Es exactamente la misma lógica que se usa en bases de datos con la orden "JOIN" de SQL.

Aunque suene a trámite informático, este paso de "preparación y cruce" es la base del éxito: representa **hasta el 80% del trabajo real** de un Data Scientist antes de poder tomar buenas decisiones.

Estructura del notebook paso a paso

Para que puedas repasarlo fácilmente sin abrumarte con el código, aquí tienes la traducción al mundo real de los 10 pasos que seguimos en el cuaderno de trabajo:

Esto es lo que hicimos en pantalla:

Paso 1. Carga rápida (Traer los datos a la mesa)

Empezamos subiendo dos archivos de datos (.csv) gigantes. En lugar de volvernos locos abriendo excels pesados, usamos Pandas. Es una librería de Python que nos permitió cargar toda esa información en apenas un segundo y echar un primer vistazo rápido para ver qué teníamos entre manos.

Paso 2. Preparación y cruce de tablas (Juntar las piezas)

Teníamos datos de clientes por un lado y datos de marketing por otro. Usamos una orden llamada merge (piensa en ello como un "BuscarV" con superpoderes) para cruzar todo. A partir de ahí, la herramienta calculó de forma automática lo que realmente nos importa: los clics, los ingresos y la rentabilidad (ROI) de esas campañas.

Paso 3. KPIs visuales (La foto general del negocio)

Ver tablas infinitas de números marea a cualquiera. Por eso usamos la herramienta Plotly para crear un panel muy visual. Con un solo vistazo, pudimos ver la "salud" de nuestra empresa ficticia: ingresos totales, gastos y el ROI global.

Paso 4. Vista de negocio por segmento (¿Quién nos da más dinero?)

Creamos un gráfico de barras interactivo para comparar nuestros tipos de clientes (los nuevos, los Premium, etc.). Esto nos chivó al instante qué grupo estaba comprando más y en cuáles el marketing era más eficiente.

Paso 5. Mapa de mix comercial, o "Sunburst" (El combo perfecto)

Este es el famoso gráfico circular interactivo que vimos en el directo. Nos permitió bucear en 3 niveles de un clic: región geográfica, cliente y su canal favorito. Es la mejor forma de detectar visualmente dónde están las combinaciones más rentables.

Paso 6. Scatter de valor de cliente (Cazando oportunidades)

Con un gráfico de dispersión enfrentamos lo que creíamos que valía un cliente frente a lo que gastaba de verdad. Además, el tamaño de cada punto nos indicaba su nivel de interacción (engagement).

Así, de forma muy visual, localizamos a los clientes con un potencial comercial brutal.

Paso 7. Heatmap de performance por canal (El termómetro del marketing)

Usamos la librería Seaborn para hacer un Mapa de Calor que nos dijera exactamente qué canal funciona mejor (Instagram, LinkedIn, Email...). Para que el gráfico no se volviera loco mezclando escalas distintas, usamos una técnica para "igualar las reglas del juego" (normalizar los datos). Así pudimos comparar peras con peras.

Paso 8. K-Means 3D interactivo (La bola de cristal del Machine Learning)

¡Aquí entramos en el nivel Pro! No le dijimos a la máquina qué buscar, sino que le dimos 5 variables y le pedimos al algoritmo K-Means (de Scikit-learn) que agrupara a los clientes por similitud. Nos devolvió un gráfico 3D increíble que podíamos rotar para descubrir grupos de clientes que a simple vista eran invisibles.

Paso 9. Perfil medio de clústeres (Entender quién es quién)


Una vez que el algoritmo nos dio esos grupos invisibles, usamos un gráfico de "radar" para entender su personalidad. Por ejemplo, en el directo vimos claramente dibujado al grupo de clientes de alto valor, pero que tenían riesgo de abandonar la empresa.

Paso 10. Oportunidad final: El Top 12 (El oro para el equipo de ventas)

Todo este proceso técnico desembocó aquí. Cruzamos las métricas clave y el código nos escupió un ranking exacto con los 12 clientes con mayor probabilidad comercial.

¡Y listo! Pasamos del caos de los datos, a una lista directa que puedes darle al equipo de ventas **para que cierren tratos hoy mismo**.

Cómo funciona la magia de K-Means (Paso a paso)



K-Means es uno de los algoritmos más famosos para hacer esto, donde la "K" es simplemente el **número de grupos que quieres que encuentre**. Funciona repitiendo un ciclo de 4 pasos hasta que todo encaja:

- **Paso 1. Inicialización (Los centros de mando):** El algoritmo tira puntos al azar llamados "centroides", que actuarán como el centro provisional de cada grupo.
- **Paso 2. Asignación (Cada oveja con su pareja):** Calcula las distancias numéricas y asigna a cada cliente al "centroide" que tenga más cerca.
- **Paso 3. Recálculo (Ajustar el centro):** Una vez repartidos, el centroide se mueve para situarse en el punto medio exacto de todos los clientes de su grupo.
- **Paso 4. Convergencia (Misión cumplida):** Repite los pasos **2 y 3** una y otra vez hasta que los puntos dejan de moverse.

Ahí, los grupos se han estabilizado y tienes clientes súper parecidos entre sí.

Para que lo entiendas mejor, vamos a usar una analogía:

Imagina que entras a una biblioteca con miles de libros mezclados sin ningún orden. El aprendizaje supervisado sería clasificarlos siguiendo las categorías que ya tienes impresas en el lomo (novela, historia, ciencia...).

El aprendizaje no supervisado sería coger esos mismos libros sin leer las etiquetas, hojearlos y decidir tú solo qué grupos tienen sentido según el contenido. **Puede que los grupos que encuentres no coincidan exactamente con las categorías convencionales, pero reflejan patrones reales que estaban ahí.**


El truco imprescindible: StandardScaler (Igualando las reglas del juego)

Como **K-Means** calcula todo midiendo distancias matemáticas, tenemos un **problema** gigante: si el engagement de un cliente va de 0 a 1, pero lo que gasta (CLV) llega a 50.000€, **el dinero aplastará al engagement en los cálculos.**

Para el algoritmo, 10.000€ de diferencia pesaría miles de veces más, aunque ambas cosas sean igual de importantes para tu negocio.

¿La solución? Usamos **StandardScaler** de la librería [Scikit-learn](#).

Es una herramienta que **"normaliza" los datos**, transformando todas las variables para que tengan la **misma escala**. Así nos aseguramos de comparar peras con peras y de que los grupos reflejen la realidad sin confundir al modelo.



a "K" y el Gráfico 3D (Lo que vimos en tu pantalla)

¿Cómo sabíamos cuántos grupos hacer? Matemáticamente existe un truco llamado "método del codo" que te dice cuándo añadir más grupos deja de ser útil. Pero la decisión final siempre es tuya: como experto en el negocio, eres tú quien decide si a la empresa le es más útil tener 3 segmentos de clientes o 5.

En la demo, como le pedimos al algoritmo que analizara 5 variables a la vez, creamos un gráfico 3D interactivo para poder visualizarlo. Lo rotamos, hicimos zoom y usamos un desplegable para cambiar de 2 a 6 grupos en tiempo real, viendo al instante cómo el algoritmo reaccionaba y creaba segmentaciones completamente distintas.

Lo que se ve en la demo: el gráfico 3D

El algoritmo K-Means hace el cálculo y te devuelve un grupo de puntos en 3D, pero no sabe qué significan.

K-Means trabaja con cinco variables simultáneamente (CLV, engagement rate, ROI, recencia y propensión al churn), lo que hace imposible visualizarlo directamente: necesitaría un espacio de cinco dimensiones.

Además, el gráfico es interactivo: se puede rotar, hacer zoom y pasar el cursor sobre cada punto para ver los datos de ese cliente concreto. El desplegable de la esquina permite cambiar en tiempo real entre 2 y 6 grupos para ver cómo cambia la segmentación.


Esto ilustra de forma muy directa algo clave del Machine Learning: el mismo algoritmo con los mismos datos puede producir resultados muy distintos según los parámetros que le fijemos.

Para representarlo en pantalla, la demo usa un gráfico de dispersión en tres dimensiones mostrando solo tres de esas cinco variables en los ejes X, Y y Z. Cada punto es un cliente, y su color indica a qué clúster ha sido asignado por el modelo.

El modelo no tiene ni idea de que un grupo son "clientes VIP a punto de fugarse".

Eso lo ves tú al cruzar tu visión estratégica con los datos y notar que ese grupo tiene un CLV muy alto y un riesgo de abandono gigante.

Ponerle **nombre** a ese segmento, decidir qué oferta enviarles y **comunicárselo al equipo de ventas** es exactamente tu trabajo como Data Scientist.



CONCEPTOS CLAVE QUE APARECEN EN LA DEMO

Para que no te pierdas con las siglas que vimos en la demo, aquí tienes el resumen rápido de nuestro idioma:

-
- **CTR (Click-Through Rate):** El % de personas que hacen clic en un anuncio tras verlo. Mide si tu mensaje atrae.
- **CVR (Conversion Rate):** El % de esos clics que finalmente compran o se registran. Mide tu efectividad real.
- **ROI (Return on Investment):** Si es 3,5, significa que por cada euro invertido, recuperas 3,5€. Es la salud financiera de tus campañas.
- **CLV (Customer Lifetime Value):** El dinero total estimado que un cliente dejará en tu empresa durante toda su vida. Te dice a quién mimar más.
- **Propensión al churn:** La probabilidad de que un cliente te abandone por la competencia. Si es 0,8, hay un 80% de riesgo de perderlo (¡alerta roja!).

Nota: No hace falta que sepas programar nada de esto de memoria ahora mismo.

El objetivo es observar el **flujo completo** —de los datos brutos a las decisiones de negocio— y empezar a familiarizarse con el entorno Jupyter.

PREPÁRATE PARA TU PRIMER DÍA COMO DATA SCIENTIST

¿Y ahora qué sigue?

Hoy hemos sentado las bases y visto de lo que eres capaz, pero en nuestra próxima sesión vamos a pasar a la acción pura.

Te vas a meter de lleno en la piel de un experto en datos en su primer día de trabajo en una empresa. Juntos, vamos a ensuciarnos las manos para resolver 3 casos 100% reales:

- 👉 Cómo predecir el comportamiento de los clientes antes de que compren.
- 👉 Cómo lograr que una IA lea y analice miles de documentos corporativos en segundos.
- 👉 Cómo multiplicar las ventas recomendando el producto perfecto.

Guarda este apunte, y asienta los conceptos. Pero también descansa la mente, porque en la próxima clase vas a ver, con tus propios ojos, el verdadero impacto que puedes generar en cualquier negocio si entiendes como usar la IA como tu copiloto.

¡Nos vemos en el próximo directo!



JORNADAS DATA SCIENCE CON IA

***ACCEDE AQUÍ A LA
SEGUNDA PARTE***

HAZ CLIC AQUÍ

BIG school